

Panduan Hands-on Pertemuan 9

Evaluasi Model: Metrik dan Validasi

Tujuan utama praktikum ini adalah membuat mahasiswa mampu mengevaluasi model prediktif secara benar, memilih metrik sesuai tujuan bisnis, membaca confusion matrix, membandingkan holdout dan cross-validation, serta menentukan threshold berdasarkan biaya kesalahan.

Komponen	Keterangan
Durasi	150 menit
Dataset	week9_customer_churn_evaluation.csv
Notebook	Minggu9_HandsOn_Evaluasi_Model_Validasi.ipynb
Output	Tabel metrik, confusion matrix, ROC/PR curve, threshold analysis, dan ringkasan rekomendasi model

Learning Outcomes

- Menjelaskan perbedaan accuracy, precision, recall, F1, ROC-AUC, dan PR-AUC.
- Menggunakan train-test split dengan stratifikasi untuk evaluasi awal model klasifikasi.
- Menerapkan Stratified K-Fold Cross-Validation untuk estimasi performa yang lebih stabil.
- Menganalisis trade-off threshold berdasarkan biaya false positive dan false negative.
- Mendeteksi indikasi underfitting dan overfitting melalui perbandingan train vs test performance.
- Menyusun rekomendasi model berdasarkan performa teknis dan dampak bisnis.

Rencana Praktikum 150 Menit

Waktu	Aktivitas	Output
0-10 menit	Review konsep evaluasi model setelah UTS	Mahasiswa memahami konteks evaluasi
10-25 menit	Load dataset, audit target, dan diskusi class balance	Target distribution dan feature list
25-45 menit	Train-test split dan pipeline preprocessing	Pipeline valid tanpa leakage
45-65 menit	Latih Logistic Regression, Random Forest, Gradient Boosting	Model kandidat
65-85 menit	Hitung holdout metrics dan confusion matrix	Tabel evaluasi awal
85-105 menit	ROC Curve dan Precision-Recall Curve	Kurva evaluasi threshold-independent
105-125 menit	Threshold analysis berbasis biaya FP/FN	Threshold rekomendasi bisnis
125-140 menit	Stratified K-Fold Cross-Validation	Mean dan std performa
140-150 menit	Summary dan diskusi rekomendasi	Kesimpulan model final

Short Discussion 1 - Target Distribution

Minta mahasiswa membandingkan proporsi kelas churn dan stay. Diskusikan mengapa accuracy bisa tampak tinggi pada dataset tidak seimbang, tetapi gagal menangkap kasus positif yang penting secara bisnis.

Pertanyaan pemandu: jika hanya 10% pelanggan churn, apa yang terjadi bila model selalu memprediksi stay?

Langkah Praktikum

No	Langkah	Instruksi
1	Load data	Baca CSV, cek shape, head, tipe data, missing value, dan distribusi target.
2	Tentukan X/y	Drop identifier, pisahkan target churn, identifikasi numeric dan categorical features.
3	Split data	Gunakan train_test_split dengan stratify=y. Jangan fit preprocessing sebelum split.
4	Buat pipeline	Gunakan SimpleImputer, StandardScaler, OneHotEncoder, ColumnTransformer.
5	Latih model	Bandingkan Logistic Regression, Random Forest, dan Gradient Boosting.
6	Evaluasi holdout	Hitung accuracy, precision, recall, F1, ROC-AUC, PR-AUC.
7	Confusion matrix	Identifikasi TP, TN, FP, FN dan implikasinya terhadap keputusan churn.
8	Threshold analysis	Ubah threshold 0.10-0.90 dan hitung cost FP/FN.
9	Cross-validation	Gunakan StratifiedKFold 5 fold dan bandingkan mean serta std performa.
10	Kesimpulan	Pilih model berdasarkan metrik, stabilitas, threshold, dan konteks bisnis.

Panduan Interpretasi Metrik

Metrik	Makna	Kapan penting
Accuracy	Proporsi prediksi benar dari seluruh prediksi.	Data relatif seimbang dan biaya kesalahan simetris.
Precision	Dari semua prediksi positif, berapa yang benar positif.	False positive mahal, misalnya fraud alert yang mengganggu pengguna.
Recall	Dari semua actual positive, berapa yang berhasil ditangkap.	False negative mahal, misalnya churn yang tidak ditangani.
F1	Rata-rata harmonik precision dan recall.	Butuh keseimbangan precision dan recall.
ROC-AUC	Kemampuan membedakan kelas di berbagai threshold.	Membandingkan ranking ability antar model.
PR-AUC	Area precision-recall curve.	Kelas positif jarang atau sangat penting.

Short Discussion 2 - Business Cost

Gunakan contoh biaya: false positive = biaya voucher retensi ke pelanggan yang sebenarnya tidak churn, sedangkan false negative = kehilangan pelanggan yang benar-benar churn. Mahasiswa diminta menentukan apakah threshold harus dinaikkan atau diturunkan.

Expected Output dari Notebook

- Tabel holdout evaluation untuk tiga model kandidat.
- Confusion matrix model terpilih.
- ROC curve dan Precision-Recall curve.
- Tabel threshold analysis dengan FP, FN, precision, recall, F1, dan business_cost.
- Tabel cross-validation berisi mean dan standard deviation setiap metrik.
- Tabel train-test gap untuk membaca underfitting/overfitting.
- File CSV hasil evaluasi yang diekspor dari notebook.

Kesalahan Umum yang Harus Dihindari

- Memilih model hanya dari accuracy tanpa melihat precision/recall.
- Menggunakan test set untuk tuning berulang-ulang.
- Melakukan preprocessing sebelum data split.
- Menganggap ROC-AUC tinggi otomatis berarti threshold 0.50 terbaik.
- Tidak membedakan metrik teknis dengan dampak bisnis.

Checklist Submit Praktikum

Item	Status
Notebook run all tanpa error	■
Tabel evaluasi holdout tersedia	■
Confusion matrix dijelaskan	■
Threshold bisnis dipilih dan dijelaskan	■
Cross-validation mean/std ditampilkan	■
Kesimpulan model final ditulis	■